郝忆秦

+8615221207413 | hyq718@sjtu.edu.cn | haoyiqin718@gmail.com | 上海，中国

教育背景

上海交通大学（SJTU）— 本科 2023 年 9 月 – 至今

语言能力：英语六级 646，法语 DELF B2
研究方向：深度学习、大语言模型预训练架构

实习经历

九坤 IQuest | 大模型预训练与架构探索 2026 年 6 月 – 至今

- **Looped LM**：系统探索 Looped Transformer 的设计空间，包括 layer / block 粒度、parallel loop、partial loop、loop state 门控、深宽比及 loop 内 KV 处理；在总参数量数 B 至数百 B 的 MoE 架构上，构建多种 loop 变体与等 FLOPs baseline 的 scaling ladder。
- **残差连接 / Effective Depth**：探索模型归一化（norm）结构改进、Depth Attention 与 mHC 的结合、mHC 与 iHC 的对比，以及多种残差跳连在不同 norm 方案下的表现。
- **Recurrent Model**：探索在不增加解码延迟的前提下，充分复用已有信息、增加模型有效计算深度的方法，以提升模型的通用与推理能力。

发表论文

Depth-Attention: Cross-Layer Value Mixing for Language Models [EMNLP2026]

提出 **Depth-Attention 跨层 Value Mixing 机制**：在每一层进行序列维度 self-attention 前，利用当前层 query 在同一 token 位置沿深度维度选择性读取早期层 key，并将其 value 混合为当前 self-attention 读取的 value state；该方法复用标准 Q/K/V 与 V-cache 槽位，**不引入额外参数**，且不增加标准 KV cache 之外的持久推理状态。

结果：在 3B Qwen3 模型上，无额外参数、无额外显存开销，在相同推理效率下，相比 vanilla Transformer，PPL 降低 0.3，下游平均准确率提升约 2 个百分点。后续进一步探索与 mHC / iHC 等方法的正交性，相关工作被 Nanbeige / AI Lab 的模型发布工作引用。

P2N: Reusing Deep Representations for Greater Effective Depth [Under Review]

提出**跨 token 深层表示复用**机制：将前一 token 的深层隐藏状态反馈至当前 token 的浅层计算，增加模型有效计算深度；通过局部核心层的 **Jacobi 迭代**实现跨 token 并行训练，解码时天然充分利用 Autoregressive decoding 中已有的 hidden state，仅增加一次向量加法，**无额外参数、无额外解码延迟**。

结果：在 Qwen Dense 和 MoE 架构上，都验证了方法的有效性：在无额外解码延时的情况下：预训练模型的 PPL 降低 0.2，通用下游平均准确率提升约 2 个百分点；相同配置进行 SFT 后，GSM8K 准确率显著提升约 11 个百分点，大幅提升模型推理能力。

Pretraining with Token-Level Adaptive Latent Chain-of-Thought [Under Review]

提出**基于 Token 级自适应潜在思维链（Latent CoT）的预训练方法**：模型在生成每个 token 之前，会沿连续的潜在思维轨迹进行推理，并采用**逐 token 自适应长度**机制（困难 token 计算更久，简单 token 提前停止），从而在**单阶段**通用文本预训练中自然学得 token 级自适应停机能力。

结果：在不同模型规模下，以更少的 FLOPs 获得更低的困惑度，并在相近计算预算下提升了下游任务表现。

Dual-Slot: From Serial Loops to Parallel Slots in Language Models [Under Review]

提出**双槽并行循环架构**：将串行 loop 重组为共享参数的 **latent slot 与 prediction slot**，利用前一 token 的深层潜在状态支持当前预测，同时并行计算供下一步使用的潜在状态，从而**降低串行 loop 带来的解码延迟**。

结果：在 Qwen Dense 和 MoE 架构上验证有效性：1B Dense 模型相比 vanilla Transformer，PPL 降低 0.25，five-shot 下游平均准确率提升约 2.3 个百分点；相同配置 SFT 后，zero-shot GSM8K 准确率提升约 5.8 个百分点。Dense 与 MoE 模型分别保留约 93%–97% 和 98%–100% 的基线解码吞吐。